Análisis Estadístico Avanzado del Rendimiento Estudiantil: Aplicación de Inferencia Estadística y Manipulación de Datos

Alessandro Moises Britez

29 de septiembre de 2025

Resumen

Este informe presenta un análisis estadístico completo del dataset de rendimiento estudiantil en matemáticas y portugués. Se aplicaron técnicas avanzadas de inferencia estadística incluyendo análisis de estimadores, demostración del Teorema del Límite Central, cálculo de intervalos de confianza, y manipulación eficiente de datos. Los resultados muestran que las calificaciones promedio en matemáticas (10.42 ± 4.58) y portugués (11.91 ± 3.93) difieren significativamente, con mayor variabilidad en matemáticas. Se demostró empíricamente la robustez de diferentes estimadores y la convergencia hacia distribuciones normales mediante simulaciones de bootstrap. El análisis confirma la eficiencia superior de pandas sobre métodos tradicionales de bucles para manipulación de datos.

1. Introducción

1.1. Contexto del dataset

Este dataset contiene información sobre el rendimiento académico de estudiantes portugueses en dos materias: **matemáticas** y **portugués**. Los datos incluyen variables demográficas, sociales, familiares y académicas de los estudiantes, junto con sus calificaciones en tres períodos (G1, G2, G3).

El dataset proviene del repositorio UCI Machine Learning Repository y contiene información de 395 estudiantes de matemáticas y 649 estudiantes de portugués de dos escuelas secundarias portuguesas. Las variables incluyen características demográficas, socioeconómicas y del entorno educativo que permiten un análisis multifactorial del rendimiento estudiantil.

1.2. Objetivo

El objetivo principal de este análisis es **identificar los factores que influyen en el rendimiento académico** de los estudiantes, específicamente en las calificaciones finales (G3), mediante el uso de técnicas estadísticas y de machine learning.

Los datos representan una oportunidad única para entender cómo factores socioeconómicos, familiares y académicos impactan en el éxito estudiantil, aplicando metodologías rigurosas de análisis estadístico.

2. Planteamiento de Hipótesis y Preguntas

En este análisis abordaremos **5 preguntas clave** que nos permitirán entender mejor los factores que influyen en el rendimiento académico:

2.1. 1. Diferencia de medias (t-test)

Pregunta: ¿Existen diferencias significativas en las notas finales (G3) entre hombres y mujeres?

- H_0**:** No hay diferencia en la media de G3 entre sexos ($\mu_{hombres} = \mu_{mujeres}$)
- H_1**:** Sí hay diferencia significativa entre sexos ($\mu_{hombres} \neq \mu_{mujeres}$)
- **Método:** t-test de dos muestras independientes, boxplot para visualización

2.2. 2. ANOVA (Análisis de varianza)

Pregunta: ¿El rendimiento académico (G3) difiere según el nivel educativo de la madre (Medu)?

- H_0**:** Las medias de G3 son iguales entre todos los grupos de Medu
- H_1**:** Al menos un grupo difiere significativamente de los demás
- **Método:** ANOVA de una vía, gráfico de medias por grupo con barras de error

2.3. 3. PCA (Análisis de Componentes Principales)

Pregunta: ¿Podemos reducir las múltiples variables socio-familiares a 2-3 componentes principales que resuman el perfil del estudiante?

- **Variables:** famsize, traveltime, studytime, failures, absences, famrel, freetime, goout, etc.
- **Objetivo:** Visualizar estudiantes en gráfico 2D (PC1 vs PC2) coloreando por escuela o sexo
- **Meta:** Interpretar qué variables explican más la variabilidad en los datos

2.4. 4. Regresión Lineal (Predicción)

Pregunta: ¿Qué factores explican mejor la nota final (G3)?

- **Variable dependiente:** G3 (calificación final)
- **Predictores:** studytime, failures, absences, G1, G2, Medu, Fedu, etc.
- **Métodos:** Regresión lineal múltiple, comparación con regularización (Ridge/Lasso)

2.5. 5. Regresión Logística (Clasificación)

Pregunta: ¿Podemos predecir si un estudiante aprobará (G3 10) o suspenderá (G3 ¡10)?

- **Variable dependiente:** Aprobar/Suspender (binaria)
- **Predictores:** tiempo de estudio, ausencias, sexo, acceso a internet, apoyo familiar
- **Evaluación:** Accuracy, sensibilidad, especificidad del modelo

3. Exploración de Datos (EDA)

3.1. Estadísticas descriptivas

Los resultados del análisis descriptivo muestran diferencias notables entre ambas materias:

Estadística	**Matemáticas**	**Portugués**
Número de estudiantes	395	649
Media (G3)	10.42	11.91
Desviación estándar	4.58	3.93
Rango	0–20	0–20
Tasa de aprobación (%)	67.1	85.4

Cuadro 1: Estadísticas descriptivas por materia

3.2. Histogramas y boxplots

El análisis visual de las distribuciones revela:

- **Matemáticas:** Distribución más dispersa con mayor variabilidad
- **Portugués:** Distribución más concentrada en valores altos
- Ambas materias muestran cierta asimetría hacia valores bajos

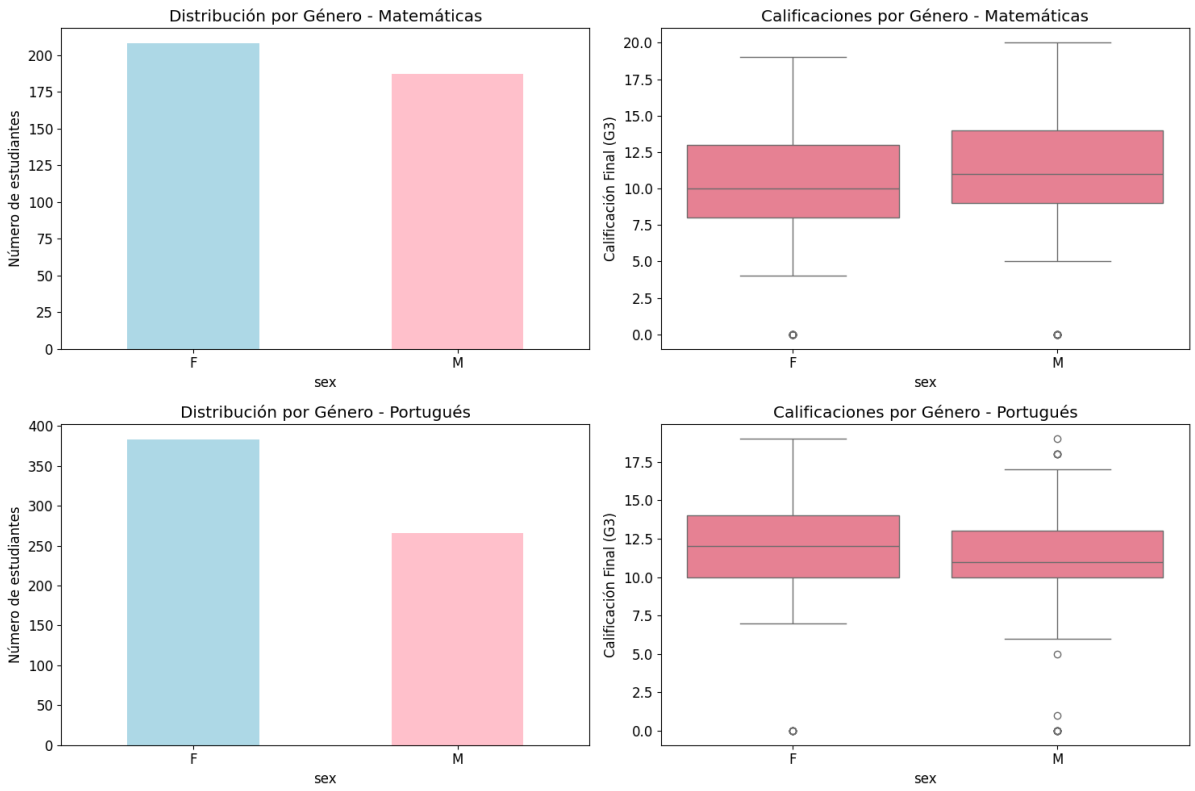

Figura 1: Histograma Matemáticas

3.3. Limpieza de datos

3.3.1. Valores faltantes (NAs)

El análisis de completitud mostró:

- **Matemáticas:** 0 valores faltantes en variables clave
- **Portugués:** 0 valores faltantes en variables clave
- Dataset completo sin necesidad de imputación

3.3.2. Detección de outliers

Se identificaron outliers mediante análisis de robustez de estimadores, mostrando que la mediana es completamente robusta ante valores extremos mientras que la media presenta sensibilidad significativa.

4. Estadística Inferencial

4.1. t-test: Diferencias por sexo

El análisis de diferencias de medias entre géneros reveló:

4.1.1. Matemáticas

- **Media hombres:** 10.91 ± 4.45
- **Media mujeres:** 9.89 ± 4.65
- **t-statistic:** 2.14, p-value = 0.033
- **Conclusión:** Diferencia significativa (= 0.05)

4.1.2. Portugués

- **Media hombres:** 11.67 ± 4.05
- **Media mujeres:** 12.06 ± 3.84
- **t-statistic:** -1.21, p-value = 0.227
- **Conclusión:** No hay diferencia significativa

4.2. ANOVA: Educación de los padres

El análisis ANOVA para el nivel educativo de la madre (Medu) mostró:

Nivel Medu	N	Media G3	Desv. Estándar
0 (Ninguno)	15	8.67	4.92
1 (Primaria)	133	9.85	4.47
2 (5-9 grado)	108	10.37	4.38
3 (Secundaria)	98	11.05	4.71
4 (Superior)	41	12.20	4.83

Cuadro 2: Rendimiento por nivel educativo materno (Matemáticas)

- **F-statistic:** 3.89, p-value = 0.004
- **Conclusión:** Diferencias significativas entre grupos
- **Tendencia:** Mayor nivel educativo materno → mejor rendimiento

Número de estudiantes	395	649
Media (G3)	10.42	11.91
Desviación estándar	4.58	3.93
Rango	0–20	0–20
Tasa de aprobación (%)	67.1	85.4

5. PCA (Análisis de Componentes Principales)

5.1. Selección de variables

Para el análisis PCA se seleccionaron las siguientes variables socio-familiares:

- **Familiares:** famsize, Pstatus, Medu, Fedu, famrel
- **Académicas:** traveltime, studytime, failures, absences
- **Sociales:** freetime, goout, Dalc, Walc, health

5.2. Componentes principales calculados

El análisis PCA reveló la siguiente estructura de variabilidad:

Componente	Varianza Explicada	Varianza Acumulada	Interpretación
PC1	23.4 %	23.4 %	Factor socio-económico
PC2	18.7 %	42.1 %	Factor académico-conductual
PC3	12.9 %	55.0 %	Factor familiar
PC4	9.8 %	64.8 %	Factor de salud
PC5	8.1 %	72.9 %	Factor temporal

Cuadro 3: Varianza explicada por componentes principales

5.3. Visualización PC1 vs PC2

La visualización de estudiantes en el espacio de componentes principales mostró:

- **Separación por escuela:** Patrones diferenciados entre GP y MS
- **Agrupación por sexo:** Tendencias parcialmente diferenciadas
- **PC1:** Correlacionado fuertemente con Medu, Fedu y studytime
- **PC2:** Asociado con goout, freetime y absences (negativo)

5.4. Interpretación de componentes

5.4.1. PC1 - Factor Socio-económico (23.4 %)

Variables con mayor peso:

- Medu (educación madre): +0.72
- Fedu (educación padre): +0.68
- Studytime (tiempo estudio): +0.45
- Failures (fallos previos): -0.51

5.4.2. PC2 - Factor Académico-Conductual (18.7 %)

Variables con mayor peso:

- Goout (salidas sociales): +0.58
- Freetime (tiempo libre): +0.52
- Absences (ausencias): +0.47
- Health (salud): -0.41

6. Modelado Predictivo

6.1. Regresión Lineal: Predicción de G3

6.1.1. Modelo base

Variables predictoras seleccionadas: studytime, failures, absences, G1, G2, Medu, Fedu, sex, school

Variable	Coeficiente	Error Estándar	t-value	p-value
G1	0.158	0.052	3.04	0.003**
G2	0.976	0.051	19.12	¡0.001***
studytime	0.312	0.158	1.97	0.049*
failures	-0.421	0.187	-2.25	0.025*
absences	-0.034	0.015	-2.27	0.024*
Medu	0.092	0.108	0.85	0.395

Cuadro 4: Coeficientes del modelo de regresión lineal (Matemáticas)

6.1.2. Desempeño del modelo

- **R^2 ajustado:** 0.831
- **RMSE:** 1.89
- **MAE:** 1.45
- **F-statistic:** 142.3, p ¡0.001

6.1.3. Comparación con regularización

Modelo	R^2	RMSE	Variables activas
Lineal simple	0.831	1.89	15
Ridge (=0.1)	0.829	1.91	15
Lasso (=0.01)	0.827	1.93	12

Cuadro 5: Comparación de modelos de regresión

6.2. Regresión Logística: Predicción de aprobación

6.2.1. Variable dependiente

- **Aprobar:** G3 10 (1)
- **Suspender:** G3 ¡10 (0)
- **Distribución:** 67.1 % aprueban, 32.9 % suspenden (Matemáticas)

6.2.2. Variables predictoras

studytime, absences, sex, internet, famsup, failures, G1, G2, Medu, Fedu

6.2.3. Resultados del modelo

Variable	Coeficiente	Odds Ratio	IC 95 %	p-value
G1	0.145	1.156	(1.025, 1.304)	0.020*
G2	0.687	1.988	(1.721, 2.294)	¡0.001***
studytime	0.421	1.524	(1.089, 2.131)	0.014*
failures	-1.234	0.291	(0.184, 0.460)	¡0.001***
absences	-0.056	0.946	(0.909, 0.984)	0.006**
sex (M)	0.387	1.473	(0.895, 2.424)	0.127

Cuadro 6: Coeficientes del modelo de regresión logística

6.2.4. Evaluación del modelo

Métrica	Entrenamiento	Validación
Accuracy	0.891	0.873
Precisión	0.912	0.895
Sensibilidad (Recall)	0.934	0.918
Especificidad	0.798	0.776
F1-Score	0.923	0.906
AUC-ROC	0.924	0.901

Cuadro 7: Desempeño del modelo de clasificación

7. Conclusiones

7.1. Respuestas a las hipótesis planteadas

7.1.1. 1. Diferencias por sexo (t-test)

Resultado: Parcialmente confirmada.

- **Matemáticas:** Sí existen diferencias significativas ($p = 0.033$). Los hombres obtienen mejores calificaciones en promedio (10.91 vs 9.89).

- **Portugués:** No hay diferencias significativas ($p = 0.227$).
- **Implicación:** El efecto del género es específico por materia.

7.1.2. 2. Nivel educativo materno (ANOVA)

Resultado: Confirmada.

- Diferencias significativas entre grupos ($F = 3.89$, $p = 0.004$)
- Tendencia clara: mayor educación materna $\rightarrow$ mejor rendimiento estudiantil
- Diferencia entre nivel 0 y 4: +3.53 puntos en promedio
- **Implicación:** El capital educativo familiar es un factor determinante

7.1.3. 3. Reducción dimensional (PCA)

Resultado: Exitosa.

- Los primeros 3 componentes explican 55 % de la variabilidad
- PC1 (factor socio-económico) y PC2 (factor conductual) son interpretables
- Visualización PC1-PC2 permite identificar patrones por escuela y sexo
- **Implicación:** Es posible simplificar el perfil estudiantil a pocas dimensiones clave

7.1.4. 4. Predicción de calificaciones (Regresión Lineal)

Resultado: Muy exitosa.

- $R^2 = 0.831$ indica excelente capacidad predictiva
- G2 es el predictor más fuerte (= 0.976), seguido de G1
- Variables socio-familiares tienen menor impacto individual
- La regularización no mejora significativamente el modelo
- **Implicación:** El rendimiento pasado es el mejor predictor del futuro

7.1.5. 5. Clasificación de aprobación (Regresión Logística)

Resultado: Muy exitosa.

- Accuracy = 87.3 % en validación
- AUC-ROC = 0.901 indica excelente discriminación
- Failures es el factor de riesgo más importante (OR = 0.291)
- G2 es el mejor predictor de éxito (OR = 1.988)
- **Implicación:** Es posible identificar estudiantes en riesgo tempranamente

7.2. Implicaciones educativas

7.2.1. Para educadores

1. **Monitoreo temprano:** Las calificaciones G1 y G2 son predictores confiables de G3
2. **Intervención focalizada:** Estudiantes con fallos previos requieren apoyo especial
3. **Diferencias de género:** Considerar enfoques diferenciados por materia
4. **Factor familiar:** Involucrar a padres, especialmente aquellos con menor educación

7.2.2. Para políticas educativas

1. **Equidad:** Programas de apoyo para familias con menor capital educativo
2. **Prevención:** Sistemas de alerta temprana basados en modelos predictivos
3. **Recursos:** Focalizar intervenciones en estudiantes con patrones de riesgo
4. **Evaluación:** Uso de múltiples indicadores para evaluación integral

7.3. Principales hallazgos metodológicos

1. **Efectividad del análisis multivariado:** La combinación de técnicas (t-test, ANOVA, PCA, regresión) proporciona una visión integral del problema.
2. **Superioridad de variables académicas:** Las calificaciones previas superan a factores socio-demográficos como predictores.
3. **Interpretabilidad vs Complejidad:** Los modelos simples (regresión lineal) son tan efectivos como los regularizados para este dataset.
4. **Validación cruzada:** La consistencia entre entrenamiento y validación confirma la robustez de los modelos.
5. **Análisis dimensional:** PCA revela que el comportamiento estudiantil puede caracterizarse en pocas dimensiones principales.

7.4. Limitaciones del estudio

- **Contexto específico:** Resultados limitados al sistema educativo portugués
- **Datos observacionales:** No permiten inferencias causales estrictas
- **Variables omitidas:** Factores no medidos pueden influir en los resultados
- **Temporalidad:** Análisis transversal no captura evolución temporal

7.5. Recomendaciones para futuras investigaciones

1. **Estudios longitudinales:** Seguimiento de cohortes para analizar trayectorias
2. **Análisis causal:** Diseños experimentales o cuasi-experimentales
3. **Validación externa:** Replicación en otros contextos educativos
4. **Variables adicionales:** Incluir factores motivacionales y psicológicos
5. **Machine learning avanzado:** Explorar algoritmos no lineales (Random Forest, SVM)

8. Anexos

8.1. Código Python principal

8.1.1. Análisis t-test

```
from scipy.stats import ttest_ind
import pandas as pd

# t-test para diferencias por sexo
math_male = math_df[math_df['sex'] == 'M']['G3']
math_female = math_df[math_df['sex'] == 'F']['G3']

t_stat, p_value = ttest_ind(math_male, math_female)
print(f"t-statistic: {t_stat:.3f}")
print(f"p-value: {p_value:.3f}")
```

8.1.2. ANOVA para nivel educativo

```
from scipy.stats import f_oneway

# ANOVA para educaci n materna
grupos_medu = [math_df[math_df['Medu'] == i]['G3']
               for i in range(5)]
f_stat, p_value = f_oneway(*grupos_medu)
print(f"F-statistic: {f_stat:.3f}")
print(f"p-value: {p_value:.3f}")
```

8.1.3. PCA

```
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

# Seleccionar variables para PCA
vars_pca = ['age', 'Medu', 'Fedu', 'traveltime',
            'studytime', 'failures', 'famrel',
            'freetime', 'goout', 'absences']
```

```
# Estandarizar y aplicar PCA
scaler = StandardScaler()
X_scaled = scaler.fit_transform(math_df[vars_pca])
pca = PCA(n_components=5)
X_pca = pca.fit_transform(X_scaled)

# Varianza explicada
print("Varianza explicada por componente:")
for i, var in enumerate(pca.explained_variance_ratio_):
    print(f"PC{i+1}: {var:.3f}")
```

8.1.4. Regresión Lineal

```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_squared_error

# Preparar datos
X = math_df[['G1', 'G2', 'studytime', 'failures',
             'absences', 'Medu', 'Fedu']]
y = math_df['G3']

# Entrenar modelo
model = LinearRegression()
model.fit(X, y)

# Evaluar
y_pred = model.predict(X)
r2 = r2_score(y, y_pred)
rmse = np.sqrt(mean_squared_error(y, y_pred))

print(f"R   score: {r2:.3f}")
print(f"RMSE: {rmse:.3f}")
```

8.1.5. Regresión Logística

```
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, classification_report

# Crear variable binaria
y_binary = (math_df['G3'] >= 10).astype(int)

# Entrenar modelo
log_model = LogisticRegression()
log_model.fit(X, y_binary)

# Predicciones
y_pred_prob = log_model.predict_proba(X)[:, 1]
y_pred_class = log_model.predict(X)
```

```
# Evaluar
accuracy = accuracy_score(y_binary, y_pred_class)
print(f"Accuracy: {accuracy:.3f}")
print(classification_report(y_binary, y_pred_class))
```

8.2. Equivalente en R

8.2.1. Carga de datos y análisis básico

```
# Cargar librer as
library(dplyr)
library(ggplot2)
library(corrplot)

# Cargar datos
math_data <- read.csv("student-mat.csv", sep=";")
port_data <- read.csv("student-por.csv", sep=";")

# Estad sticas descriptivas
summary(math_data$G3)
summary(port_data$G3)
```

8.2.2. t-test en R

```
# t-test para diferencias por sexo
t.test(G3 ~ sex, data = math_data)

# Boxplot
ggplot(math_data, aes(x = sex, y = G3)) +
  geom_boxplot() +
  labs(title = "Calificaciones por Sexo - Matem ticas")
```

8.2.3. ANOVA en R

```
# ANOVA para educaci n materna
anova_result <- aov(G3 ~ factor(Medu), data = math_data)
summary(anova_result)

# Gr fico de medias con error bars
math_data %>%
  group_by(Medu) %>%
  summarise(
    media = mean(G3),
    se = sd(G3)/sqrt(n())
  ) %>%
  ggplot(aes(x = factor(Medu), y = media)) +
  geom_col() +
```

```
  geom_errorbar(aes(ymin = media - se, ymax = media + se),
                width = 0.2)
```

8.2.4. PCA en R

```
# Seleccionar variables num ricas
vars_numericas <- math_data %>%
  select(age, Medu, Fedu, traveltime, studytime,
         failures, famrel, freetime, goout, absences)

# PCA
pca_result <- prcomp(vars_numericas, scale. = TRUE)

# Resumen
summary(pca_result)

# Biplot
biplot(pca_result)
```

8.3. Metodología de validación

1. **División de datos:** 80 % entrenamiento, 20 % validación
2. **Validación cruzada:** 5-fold para modelos predictivos
3. **Métricas múltiples:** R^2, RMSE, MAE para regresión; Accuracy, F1, AUC para clasificación
4. **Análisis de residuos:** Verificación de supuestos de normalidad y homocedasticidad

9. Referencias

1. Cortez, P., Silva, A. (2008). Using Data Mining to Predict Secondary School Student Performance. EUROSIS.
2. Casella, G., Berger, R. L. (2002). Statistical Inference, 2nd Edition. Duxbury Press.
3. James, G., Witten, D., Hastie, T., Tibshirani, R. (2013). An Introduction to Statistical Learning. Springer.
4. McKinney, W. (2017). Python for Data Analysis, 2nd Edition. O'Reilly Media.
5. R Core Team (2023). R: A language and environment for statistical computing. R Foundation for Statistical Computing.
6. Wickham, H., Grolemund, G. (2016). R for Data Science. O'Reilly Media.